

Automatentheorie

Reguläre Grammatiken

Prof. Dr. Franz-Karl Schmatzer
schmatzf@dhbw-loerrach.de

Literatur

- C.Wagenknecht, M.Hielscher; Formale Sprachen, abstrakte Automaten und Compiler; 2.Aufl. Springer Vieweg 2014;
- A.V.Aho, M.S.Lam,R.Savi,J.D.Ullman, *Compiler – Prinzipien,Techniken und Werkzeuge*. 2. Aufl., Pearson Studium, 2008.
- Güting, Erwin; *Übersetzerbau –Techniken, Werkzeuge, Anwendungen*, Springer Verlag 1999
- Sipser M.; Introduction to the Theory of Computation; 2.Aufl.; Thomson Course Technology 2006
- Hopcroft, T. et al; Introduction to Automata Theory, Language, and Computation; 3. Aufl. Pearson Verlag 2006

Agenda

- Einführung in Grammatiken
- Rechts und linkslineare Grammatiken
- Einteilung der Grammatiken
- Typ-3 Grammatiken
- Aufbau von Typ-3 Grammatiken

Grammatiken

Einführung

- Ein Satz einer gesprochenen Sprache ist ein recht komplexes Gebilde, zeigt aber bei genauerem Hinsehen regelmäßige Strukturen auf, die die Bildung von Wörtern nach Regeln erlaubt.
- Im Deutschen z.B. findet man folgende Struktur (nur ein Ausschnitt):
 - Ein Satz <S> kann aus einer Nominalphase <NP> und einer Verbalphase <VP> zusammengesetzt sein.
 - In der Nominalphase herrscht das Nomen <N> vor. Ein Nomen kann ein Determinator <D> haben oder durch Konjunktionen <K> verbunden sein.
 - In der Verbalphase <VP> herrscht das Verb <V> vor. Das Verb kann wieder mit einer Nominalphase oder mit einer Präpositionalphase <PP> verbunden sein.
 - Die Präpositionalphase <PP> setzt sich aus einer Präposition <P> und einer Nominalphase zusammen.

Grammatiken

Einf hrung Regeln

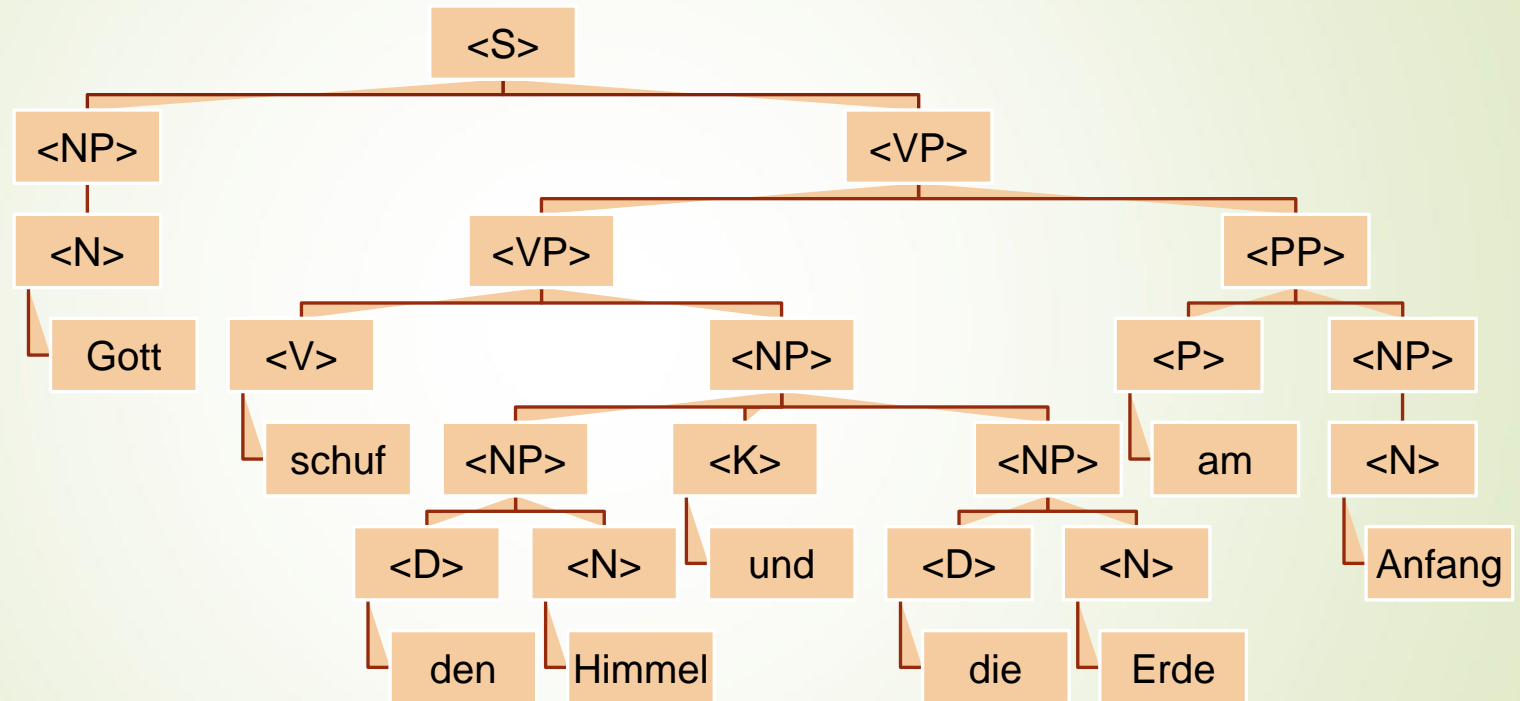
- Ein m glicher Ausschnitt aus der deutschen Grammatik

<S>	→	<NP><VP>
<NP>	→	<N> <D><N> <NP> <K> <NP>
<VP>	→	<V> <NP> <VP><PP>
<PP>	→	<P> <NP>
<K>	→	und
<N>	→	Gott Himmel Erde Anfang
<V>	→	schuf
<D>	→	die den
<P>	→	am

- Man findet hier Variablen (<S>, <D>, usw.,) und Terminale (am, Gott,) mit denen S tze tats chlich gebildet werden.
- Ein m glicher Satz wird gebildet indem man bei dem Startsymbol <S> beginnend die einzelnen Regeln solange anwendet bis alle Variablen durch Terminale ersetzt werden.

Grammatiken

Einführung Ableitung



- Eine Ableitung des Satzes:
- Gott schuf den Himmel und die Erde am Anfang

Grammatiken

Formale Definition

Grammatiken werden formal definieren als:

- Eine Grammatik G besteht aus 4 Komponenten (N, Σ, P, S) mit:
 - N eine endliche Menge von Variablen (Nichtterminale).
 - Σ ist ein Alphabet aus Terminalen mit $N \cap \Sigma = \emptyset$.
 - Statt Σ schreibt man oft T (Terminalen), d.h. (N, T, P, S)
 - P ist eine Menge von Produktionen (Regeln).
 - Eine Produktion ist ein Element $P=(L,R) \in (N \cup \Sigma)^* \times (N \cup \Sigma)^*$.
 - Mit $l \in L$ und $r \in R$ schreibt man statt (l, r) besser: $l \rightarrow_P r$ bzw. $l \rightarrow r$
 - $S \in N$ ist eine Startvariable

Grammatiken

Definition Ableitung, Sprache Äquivalenz

Die Ableitung eines Wortes:

Sei $G = (N, \Sigma, P, S)$ eine Grammatik, und seien $v, w \in (N \cup \Sigma)^*$, so gilt $v \Rightarrow w$ (d.h. v geht in w über), falls gilt:

$\exists x, y \in (N \cup \Sigma)^*$ und eine Produktion $P \rightarrow Q$ so dass $v = xPy$ und $w = xQy$ ist.

Gibt es eine Folge von Produktionen, die eine Ableitung v nach w implizieren schreibt man $v \Rightarrow^* w$

Die Sprache $L(G)$

Die von einer Grammatik G erzeugte Sprache $L(G)$ ist die Menge aller terminalen Wörter, die durch G vom Startsymbol aus erzeugt werden können.

$$L(G) = \{ w \in \Sigma^* \mid S \Rightarrow_G^* w \}$$

Äquivalenz $L(G_1) = L(G_2)$

Zwei Grammatiken G_1, G_2 heißen äquivalent $\Leftrightarrow L(G_1) = L(G_2)$

Beispiel einer Grammatik

Wortableitung

Grammatik $G = (N, T, P, s)$ mit

$N = \{S, A, B\}$

$T = \{a, b, c\}$

$P = \{S \rightarrow aS \mid cS \mid bA, A \rightarrow bA \mid cB, B \rightarrow Bc \mid c\}$

$s = S$

Wortableitung

- $w = aabbbcc$
- $S \Rightarrow aS \Rightarrow aaS \Rightarrow aabA \Rightarrow aabbA \Rightarrow aabbbA \Rightarrow aabbbcbB \Rightarrow aabbbcc$
(fertig)
- $w = ccbba$
- $S \Rightarrow cS \Rightarrow ccS \Rightarrow ccbA \Rightarrow ccbba$? Wort nicht ableitbar

Grammatiken

Einteilung I

- Die Grammatiken mit den allgemeinen Produktionen P sind sehr komplex und schwer zu durchschauen.
- Daher teilt man die Grammatiken weiter ein, indem man die Möglichkeiten für die Produktionen einschränkt. (Chomsky-Hierarchie)
- Eine Grammatik $G = (N, \Sigma, P, S)$ mit $P = (L, R)$ heißt
 - Regulär $\Leftrightarrow \forall L \rightarrow R \text{ gilt: } L \in N$
 und $R \in (\{\epsilon\} \cup \Sigma \cup \Sigma N)$
 oder $R \in (\{\epsilon\} \cup \Sigma \cup N \Sigma)$
 - Rechtslinear $\Leftrightarrow \forall L \rightarrow R \text{ gilt: } L \in N \text{ und } R \in (\{\epsilon\} \cup \Sigma \cup \Sigma N)$
 - Linkslinear $\Leftrightarrow \forall L \rightarrow R \text{ gilt: } L \in N \text{ und } R \in (\{\epsilon\} \cup \Sigma \cup N \Sigma)$

Grammatiken

Einteilung II

- Eine Grammatik $G = (N, \Sigma, P, S)$ mit $P = (L, R)$ heißt
 - kontextfrei $\Leftrightarrow \forall L \rightarrow R \text{ gilt: } L \in N \text{ und } R \in (\Sigma \cup N)^*$
 - kontextsensitiv $\Leftrightarrow \forall L \rightarrow R \text{ gilt: } L \in (N \cup \Sigma)^* N (N \cup \Sigma)^*$
und $R \in (\Sigma \cup N)^*$
 - Entweder $\exists u, v, w \in (N \cup \Sigma)^*$ und $\exists A \in N$, so dass $L = uAv$ und $R = uwv$ und $|w| \geq 1$ oder die Produktion hat die Form $S \rightarrow \varepsilon$
 - S kommt nicht in R (das heißt auf der rechten Seite) vor.
 - beschränkt $\Leftrightarrow \forall L \rightarrow R \text{ gilt:}$
 - Entweder $|L| \leq |R|$ oder die Produktion hat die Form $S \rightarrow \varepsilon$.
 - S kommt nicht in R (das heißt auf der rechten Seite) vor.

Grammatiken

Formale Einteilung

Sprachklasse	definiert	Name der Klasse
L_3	$\{L(G) \mid G \text{ ist regulär}\}$	Regulär, Typ 3
L_2	$\{L(G) \mid G \text{ ist kontextfrei}\}$	Kontextfrei, Typ 2
L_1	$\{L(G) \mid G \text{ ist kontextsensitiv}\}$	Kontextsensitiv, Typ 1
	$\{L(G) \mid G \text{ ist beschränkt}\}$	
L_0	$\{L(G) \mid G \text{ ist eine Grammatik}\}$	Rekursiv aufzählbar, Typ 0
L	$\{L \subseteq T^* \mid T \text{ ist ein Alphabet}\}$	Sprache

Chomsky-Hierarchie

Es gilt: $L_3 \subset L_2 \subset L_1 \subset L_0 \subset L$

d.h. jeder der Sprachen L_i ist eine echte Obermenge zu der nächsten Sprache L_{i+1}

Grammatiken

Beispiele

- $L(A) = \{a^n \mid n > 0\}$ (Typ3 Grammatik)
 - Sie wird erzeugt von der Grammatik $G = (\{S\}, \{a\}, \{S \rightarrow aS \mid a\}, S)$
- $L(A) = \{a^n b^n \mid n > 0\}$ (Typ2 Grammatik)
 - Sie wird erzeugt von der Grammatik $G = (\{S\}, \{a, b\}, \{S \rightarrow aSb \mid ab\}, S)$
- $L(A) = \{a^n b^n c^n \mid n > 0\}$ (Typ1 Grammatik)
 - Sie wird erzeugt von der Grammatik $G = (\{S, A, B, C\}, \{a, b, c\}, P, S)$ mit $P =$
 - $\{$
 - $S \rightarrow aSBC \mid aBC,$
 - $CB \rightarrow BC,$
 - $aB \rightarrow ab,$
 - $bB \rightarrow bb,$
 - $bC \rightarrow bc,$
 - $cC \rightarrow cc \}$

Aufgabe Grammatiktypen

Von welchem Typ sind folgende Grammatiken $G=(N, \{0,1\}, P, S)$. Geben Sie dazu auch Worte der Sprache an und überprüfen anhand einer Ableitung, ob $w \in L(G)$ ist

1. $N=\{S,A\}$, $P=\{S \rightarrow 0A, A \rightarrow 0A \mid 1\}$ $w=001$
2. $N=\{S,B\}$, $P=\{S \rightarrow B1, B \rightarrow B0 \mid 0\}$ $w=001$
3. $N=\{S,A,B,C\}$, $P=\{S \rightarrow 0S \mid 1S \mid 0A, A \rightarrow 1B, B \rightarrow 0C, C \rightarrow \varepsilon\}$ $w=11010$
4. $N=\{S,A\}$, $P=\{S \rightarrow 0A, A \rightarrow 0A1 \mid 1\}$ $w=000111$
5. $N=\{S,A,B\}$, $P=\{S \rightarrow 0A0 \mid 1B1, A \rightarrow 1A0 \mid \varepsilon, B \rightarrow 0B1 \mid \varepsilon\}$ $w=011000$
6. $N=\{S,A,B\}$, $P=\{S \rightarrow 0AB \mid 1BA, 0A \rightarrow 01B0 \mid \varepsilon, 1B \rightarrow 00A1 \mid 1, 0B \rightarrow 1\}$ $w=00101$

Grammatiken

Wort-Ableitung

- Leiten Sie das Wort $w = a^4$ für vorherige Typ3 Grammatik ab.
- Leiten Sie das Wort $w = a^4 b^4$ für vorherige Typ2 Grammatik ab.
- Leiten Sie das Wort $w = a^4 b^4 c^4$ für vorherige Typ1 Grammatik ab.

Typ-3-Grammatiken

Einführung

- Man unterscheidet
 - rechtslineare und
 - linkslineare Grammatiken
- Beispiel: $G = (\{S, A, B\}, \{0, 1\}, P, S)$ mit
 - $P = \{ S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0A, A \rightarrow 0B, A \rightarrow 1B, B \rightarrow 0, B \rightarrow 1 \}$
- Wie werden nun Wörter gebildet?
 - Anwenden der Regeln $uA \Rightarrow uw$ genau dann, wenn $A \rightarrow w \in P$
 - Ableiten solange möglich, bis nur noch Terminalsymbole übrig sind.
 - Alle möglichen Ableitungen (reflexive Hülle) definiert die Sprache $L(G)$
$$L(G) = \{ w \in \Sigma^* \mid S \Rightarrow^* w \}$$
- Zwei Grammatiken G_1 und G_2 heißen äquivalent wenn $L(G_1) = L(G_2)$

Typ-3-Grammatiken

formale Definition

- Eine rechtslineare Grammatik $G = (N, \Sigma, P, S)$ wird definiert als
 - N eine Menge von Nicht-Terminalsymbolen, die zu Σ disjunkt ist.
 - Σ eine Menge von Terminalsymbolen
 - P eine Relation $\subseteq N \times (\Sigma^* N \cup \Sigma \cup \{\epsilon\})$
 - $S \in N$, dem Startsymbol
 - Ein Element $p \in P$ mit $P = (L, R)$ und $p = (l, r)$ heißt Produktion oder Regel mit
 - $l \in N$ und $r \in \{\Sigma^* N \cup \Sigma \cup \{\epsilon\}\}$ und der Notation: $l \rightarrow r$
(l geht über in r oder l wird durch r ersetzt)
 - D.h. auf bei einer Produktion $l \rightarrow r$ stehen alle Nicht-Terminalsymbole N nur rechts von den Terminalsymbolen Σ in r .

Typ-3-Grammatiken

Beispiel rechtslineare Grammatik: Ableitung

➤ $G = (\{S, A, B\}, \{0, 1\}, P, S)$ mit

➤ $P = \{S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0A, A \rightarrow 0B, A \rightarrow 1B, B \rightarrow 0, B \rightarrow 1\}$

➤ Ableiten eines Wortes $w = 01001$

1. Starten mit S

2. Schauen welche Regeln mit S beginnen, dann Anwenden einer dieser Regeln.

3. Solange fortfahren, bis nur noch Terminalsymbolen übrig sind.

➤ $S \Rightarrow 0S$ (Regel $S \rightarrow 0S$)

➤ $S \Rightarrow 01S$ (Regel $S \rightarrow 1S$)

➤ $S \Rightarrow 010A$ (Regel $S \rightarrow 0A$)

➤ $S \Rightarrow 0100B$ (Regel $A \rightarrow 0B$)

➤ $S \Rightarrow 01001$ (Regel $B \rightarrow 1$)

➤ **$S \Rightarrow^* 01001$ und damit $01001 \in L(G)$**

Typ-3-Grammatiken

formale Definition

- Eine linkslineare Grammatik $G = (N, \Sigma, P, S)$ wird genauso wie eine rechtslineare Grammatik definiert außer
 - P eine Relation $\subseteq N \times (N\Sigma \cup \Sigma \cup \{\epsilon\})$, d.h. $l \in N$ wie oben aber r wird zu $r \in (N\Sigma \cup \Sigma \cup \{\epsilon\})$
 - D.h. auf bei einer Produktion $l \rightarrow r$ stehen alle Nicht-Terminale N nur links von den Terminalen Σ in r .

Typ-3-Grammatiken

Beispiel linkslineare Grammatik: Ableitung

- $G = (\{S, A, B\}, \{0, 1\}, P, S)$ mit
 - $P = \{S \rightarrow S0, S \rightarrow S1, S \rightarrow A0, A \rightarrow B0, A \rightarrow B1, B \rightarrow 0, B \rightarrow 1\}$
- Ableiten eines Wortes
 1. Starten mit S
 2. Schauen welche Regeln mit S beginnen, dann Anwenden einer dieser Regeln.
 3. Solange fortfahren, bis nur noch Terminalsymbolen übrig sind.
 - $S \Rightarrow S0$ (Regel $S \rightarrow S0$)
 - $S \Rightarrow S10$ (Regel $S \rightarrow S1$)
 - $S \Rightarrow A010$ (Regel $S \rightarrow A0$)
 - $S \Rightarrow B$ (Regel $A \rightarrow B0$)
 - $S \Rightarrow$ (Regel $B \rightarrow 1$)
 - **$S \Rightarrow^* 10010$ und damit $10010 \in L(G)$**

Typ-3-Grammatiken

rechts- und linkslineare Grammatik

- Eine rechtslineare Grammatik hat auf der linken Seite immer ein nicht Terminalsymbol und auf der rechten Seite ein Wort aus $\Sigma N \cup \Sigma \cup \{\varepsilon\}$, d.h. $(A, B \in N, a \in \Sigma)$
 - $A \rightarrow aB$ (1)
 - $A \rightarrow a$ (2)
 - $A \rightarrow \varepsilon$ (3)
- Eine linkslineare Grammatik hat auf der linken Seite immer ein nicht Terminalsymbol und auf der rechten Seite ein Wort aus $N\Sigma \cup \Sigma \cup \{\varepsilon\}$, d.h. $(A, B \in N, a \in \Sigma)$
 - $A \rightarrow Ba$ (1)
 - $A \rightarrow a$ (2)
 - $A \rightarrow \varepsilon$ (3)

Typ-3-Grammatiken

Vereinfachte Grammatik

- Statt der 3 Regeln (1) bis (3) lässt sich die Grammatik vereinfachen und nur mit Regeln (1) und (3) erstellen
- Jede Regel (2) $A \rightarrow a$ wird ersetzt durch:
 - $A \rightarrow aT$ bzw. $A \rightarrow Ta$ (1) T ein neues nicht Terminalsymbol
 - $T \rightarrow \varepsilon$ (3)
- Beispiel: $G = (\{S, A, B\}, \{0, 1\}, P, S)$ mit
 - $P = \{S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0A, A \rightarrow 0B, A \rightarrow 1B, B \rightarrow 0, B \rightarrow 1\}$
 - Ersetzen von P durch P_R
 - $P_R = \{S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0A, A \rightarrow 0B, A \rightarrow 1B, B \rightarrow 0T, B \rightarrow 1T, T \rightarrow \varepsilon\}$

Erzeugen von Grammatiken

Reguläre Ausdrücke

- Der Ausdruck $L=a^*$ ergibt die Produktion $S \rightarrow aS \mid \varepsilon$
- Der Ausdruck $L=(a+b)B$ ergibt die Produktion $S \rightarrow aB \mid bB$

Aufgabe Typ3 Grammatiken

reguläre Ausdrücke

- Erstellen Sie eine rechtslineare Grammatik zu folgenden regulären Ausdrücken
 - $R = (a+b)^*c$
 - $R = (0+1)^*11$
 - $R = 0^*11^*011^*$
 - $R = (a+b)c^*b^*a$
 - $R = (0+1)(11)^*0$
 - $R = (0+1)^*01(0+1)(0+1)$

Typ-3-Grammatiken

Äquivalenz Typ-3-Grammatik und endliche Automaten

- Zu jeder Typ-3 Grammatik G über das Alphabet Σ existiert ein endlicher Automat A über S mit $L(G) = L(A)$
- Beweis in 2 Schritten
 - Sei $G = (N, \Sigma, P, S)$ eine rechtslineare Grammatik dann existiert ein Automat $A = (Q, \Sigma, \delta, s_0, F)$ mit $L(G) = L(A)$
 - Sei $A = (Q, \Sigma, \delta, s_0, F)$ ein endlicher Automat dann existiert ein Grammatik $G = (N, \Sigma, P, S)$ mit $L(G) = L(A)$

Typ-3-Grammatiken

Äquivalenz $G \Rightarrow A$

■ Beweis durch Konstruktion:

- Sei $G = (N, \Sigma, P, S)$ eine rechtslineare Grammatik, die nur die Regeln (1) und (3) enthält.
- $A = (Q, \Sigma, \delta, s_0, F)$ sei definiert als:
- Die Zustandsmenge $S \in A$ besteht aus den nicht Terminalsymbolen N
- Das Startsymbol S von G wird Startzustand S_0 von A
- Die Endzustandsmenge F von A enthält alle nicht Terminalsymbole, zu denen eine ε -Regel existiert.
- Die Zustandsübergänge ergeben sich aus den Produktionsregeln
 - Regeln $B \rightarrow aC$ ergeben $(B, a, C) \in \delta$,
 - Regeln $B \rightarrow \varepsilon$ ergeben keine Zustandsübergänge
 - Formal $\delta = \{(B, a, C) \mid B \rightarrow aC \in P\}$

Typ-3-Grammatiken


Äquivalenz $G \Rightarrow A$ Beispiel

- Gegeben die Grammatik $G = (\{S, B, C, T\}, \{0, 1\}, P, S)$ mit

$P = \{S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0B, B \rightarrow 0C, B \rightarrow 1C,$

$C \rightarrow 0T, C \rightarrow 1T, T \rightarrow \varepsilon\}$

Der Automat $A = (\{S, B, C, T\}, \{0, 1\}, \delta, S, T)$



δ	0	1
S	{S,B}	{S}
B	{C}	{C}
C	{T}	{T}
T	\emptyset	\emptyset

Typ-3-Grammatiken

Äquivalenz $A \Rightarrow G$

➤ Beweis durch Konstruktion:

- Sei $A = (Q, \Sigma, \delta, s_0, F)$ ein endlicher Automat. Wir konstruieren einen Grammatik $G = (N, \Sigma, P, S)$
- $N = Q$ (Die Nicht-Terminale sind gerade die Zustände)
- Σ der Grammatik und Σ des Automaten sind identisch.
- Wir geben und die Produktionen P (Regeln) an:
 - Falls $\delta(s, a) = s'$ dann ist $s \rightarrow as'$ eine Regel,
 - Falls $s \in F$ dann ist $s \rightarrow \varepsilon$ eine Regel
 - Formal $P = \{s \rightarrow as' \mid \delta(s, a) = s'\} \cup \{s \rightarrow \varepsilon \mid s \in F\}$

Typ-3-Grammatiken


Äquivalenz $A \Rightarrow G$ Beispiel

- Gegeben der Automat $A = (\{S, B, C, F\}, \{0, 1\}, \delta, S, F)$

Konstruktion nach vorherigem Satz

$P = \{S \rightarrow 0S, S \rightarrow 1S, S \rightarrow 0B, B \rightarrow 0C, B \rightarrow 1C,$
 $C \rightarrow 0F, C \rightarrow 1F, F \rightarrow \varepsilon\}$

Die Grammatik $G = (\{S, B, C, F\}, \{0, 1\}, P, S)$



δ	0	1
S	{S,B}	{S}
B	{C}	{C}
C	{F}	{F}
F	\emptyset	\emptyset

Aufgabe Typ3-Grammatik

Umwandeln in einen Automaten

Konstruieren Sie einen endlichen Automaten aus folgender regulären Grammatik G

1. $G=\{S,A\}, P=\{S\rightarrow 0A, A\rightarrow 0A \mid 1\}$
2. $G=\{S,A,B\}, P=\{S\rightarrow 1S \mid 0A, A\rightarrow 1A \mid 0B, B\rightarrow 1B \mid 0A \mid \varepsilon\}$
3. $G=\{S,A,B\}, P=\{S\rightarrow 0A \mid 1B, A\rightarrow 0S \mid 0, B\rightarrow 1S \mid 1\}$