Compilerbau LL(K)-Parser 2

Prof. Dr. Franz-Karl Schmatzer schmatzf@dhbw-loerrach.de

#### 2 Literatur

- C.Wagenknecht, M.Hielscher; Formale Sprachen, abstrakte Automaten und Compiler; 3.Aufl. Springer Vieweg 2022;
- U.Meyer; Grundkurs Compilerbau; Rheinwerkverlag, 1. Aufl. 2021
- A.V.Aho, M.S.Lam,R.Savi,J.D.Ullman, Compiler Prinzipien, Techniken und Werkzeuge. 2. Aufl., Pearson Studium, 2008.
- Güting, Erwin; Übersetzerbau –Techniken, Werkzeuge, Anwendungen, Springer Verlag 1999

# Top-Down-Analyse Agenda

- ► LL(k)-Parser
  - First und Follow-Mengen
  - Prädikativer Parser

### LL(K) Grammatiken

#### Charakterisierung

Problem wie findet man bei einer Produktion

$$A \rightarrow \alpha_1 | \alpha_2 | \alpha_3 | \dots | \alpha_n$$

die richtige rechte Seite, wenn man k Terminalzeichen vorausschauen kann.

- Dazu definiert man zuerst die Menge
  - ightharpoonup FIRST<sub>k</sub>( $\alpha$ ) und
  - FOLLOW<sub>k</sub>(A)
- ▶ Darauf aufbauend definiert man Steuermengen D(A $\rightarrow \alpha_i$ )
- Eine starke LL(K) Grammatik hat disjunkte Steuermengen, so dass eindeutig eine Produktion ausgewählt werden kann.

### LL(K) Grammatiken

Definition FIRST<sub>k</sub>( $\alpha$ ) und FOLLOW<sub>k</sub>(A)

Sei  $G = (N, \Sigma, P, S)$  eine kontextfreie Grammatik,  $\alpha \in (N \cup \Sigma)^*$ , k >0. Dann ist:

 $FIRST_k(\alpha) := start_k(\{w \mid \alpha \Rightarrow^* w\})$ 

Die Menge FIRST<sub>k</sub>( $\alpha$ ) beschreibt gerade die Anfangsstücke bis zur Länge k von aus  $\alpha$  ableitbaren Terminalworte

Sei G =  $(N,\Sigma,P,S)$  eine kontextfreie Grammatik,  $A \in N$ , k > 0. Dann ist:

 $FOLLOW_k(A) := \{w \mid S \Rightarrow^* uAv \text{ und } w = FIRST_k(v)\}$ 

FOLLOW<sub>k</sub>(A) beschreibt also Terminalzeichenfolgen bis zur Länge k, die innerhalb einer Ableitung in G auf das Nichtterminal A folgen können.

Berechnung von FIRST-Mengen

#### Algorithmus:

- Sei a ein Terminal dann ist: First(a) = {a}
- Sei A ein Nichtterminal mit A  $\rightarrow \alpha_1 \mid \alpha_2 \mid \alpha_3 \mid \dots \mid \alpha_n$  dann ist: First(A) = First( $\alpha_1$ )  $\cup$  First( $\alpha_2$ )  $\cup$  First( $\alpha_3$ )  $\dots$   $\cup$  First( $\alpha_n$ )
- Sei A ein Nichtterminal mit  $A \to \alpha_1 \alpha_2 \alpha_3 \alpha_n$  dann ist: First(A) = First( $\alpha_1$ )First( $\alpha_2$ )First( $\alpha_3$ ) ... First( $\alpha_n$ ) (Konkatenation)  $\alpha \in FIRST(A)$ , falls  $\alpha \in FIRST(\alpha_k)$  und  $\alpha \in FIRST(\alpha_i)$  für alle  $\alpha \in FIRST(\alpha_i)$
- Rekursiv anwenden bis nur noch Terminale auftreten.

Beispiel: Berechnung von FIRST-Mengen

Beispiel G = ({S,A,B},{a,b,c,d},P,S) mit P:

$$S \rightarrow ABCd$$
  
 $A \rightarrow a \mid B$   
 $B \rightarrow b \mid \epsilon$ 

- Die FIRST-Mengen für k=1
  - First<sub>1</sub>(B) =  $\{b, \epsilon\}$
  - First<sub>1</sub>(A) = {a}  $\cup$  FIRST<sub>1</sub>(B) = {a, b,  $\varepsilon$ }
  - First<sub>1</sub>(S) =  $FIRST_1(ABcd) = \{a, b, c\}$
- Bauen Sie die Grammatik in FLACI nach und Bestimmen Sie die First-Mengen

Berechnung von FOLLOW-Mengen

#### Algorithmus:

- Initialisiere FOLLOW(S) mit {\$}(\$ ist ein Eingabeende-Zeichen und nicht Teil des Eingabealphabet)
- Für jede Produktion A  $\rightarrow \alpha$ B $\beta$  und  $\beta \neq \epsilon$ : Füge alle Symbole von FIRST( $\beta$ ) ohne  $\{\epsilon\}$  in FOLLOW(B),
- Für jede Produktion A  $\rightarrow \alpha$ B oder A  $\rightarrow \alpha$ B $\beta$  mit  $\epsilon \in FIRST(B)$ : Füge alle Symbole aus FOLLOW(A) in FOLLOW(B) ein.
- Rekursiv anwenden bis nur noch Terminale auftreten.

Beispiel: Berechnung von FOLLOW-Mengen

Beispiel G = ({S,A,B},{a,b,c,d},P,S) mit P:

$$S \rightarrow ABCd$$

$$A \rightarrow a \mid B$$

$$B \rightarrow b \mid \epsilon$$

- Berechnen der FOLLOW-Mengen für k=1
  - $\blacksquare$  FOLLOW<sub>1</sub>(S) = {\$}
  - ightharpoonup FOLLOW<sub>1</sub>(A) = FIRST<sub>1</sub>(Bcd) = {b, c}
  - ► FOLLOW<sub>1</sub>(B) = FIRST<sub>1</sub>(cd)  $\cup$  FOLLOW<sub>1</sub>(A)= {b,c}
- Die FIRST-Mengen
  - ightharpoonup First<sub>1</sub>(B) = {b, $\epsilon$ }
  - First<sub>1</sub>(A) = { $a, b, \epsilon$ }
  - $First_1(S) = \{a, b, c\}$

## LL(K) Grammatiken

Definition Steuermengen D( $A\rightarrow\alpha_i$ )

Sei  $G = (N, \Sigma, P, S)$  eine kontextfreie Grammatik,  $A \in N$ , k > 0 und sei  $A \rightarrow \alpha_1 \mid \alpha_2 \mid \alpha_3 \mid \dots \mid \alpha_n$  die Mengen der A Produktionen. Dann ist für  $1 \le i \le n$  die Steuermenge  $D_k(A \rightarrow \alpha_i)$  definiert als:

 $D_k(A \rightarrow \alpha_i) := start_k(FIRST_k(\alpha_i)FOLLOW_k(A))$ 

- Bem: Die Steuermenge besteht aus den First-Mengen und falls die Worte kleiner k sind werden die Follow-Mengen konkateniert.
- Man kann zeigen, dass genau dann wenn die Steuermengen für eine Produktion A disjunkt sind, es sich um eine starke LL(K) Grammatik handelt.
- Im folgend betrachten wir LL(1) Grammatiken n\u00e4her.
  - Bestimmen FIRST- und FOLLOW-Mengen so wie die Steuermengen D

### LL(K) Grammatiken

Berechnen der Steuermengen D( $A\rightarrow\alpha_i$ )

Beispiel G = ({S,A,B},{a,b,c,d},P,S) mit P:

$$S \rightarrow ABCd$$

$$A \rightarrow a \mid B$$

$$B \rightarrow b \mid \epsilon$$

Die Steuermengen für G

Firstmengen

Steuermengen

Followmengen

**{\$}** 

{b,c}

{b,c}

### Aufgabe First-Follow-Mengen

Gegeben sei die folgende Grammatik G=(N,  $\Sigma$ ,P,E)

- Berechnen Sie die FIRST-Mengen.
- Bestimmen Sie die Follow-Mengen.
- Bestimmen Sie die initialen Steuermengen.
- N = {E,E',T,T',F},  $\Sigma$  = {+,\*,(,),id} und P = { E  $\rightarrow$  TE', E'  $\rightarrow$  +TE' |  $\varepsilon$ , T  $\rightarrow$  FT', T'  $\rightarrow$  \*FT' |  $\varepsilon$ , F  $\rightarrow$  (E) | id}
- N = {S,A,B},  $\Sigma$  = {a,b,c,d} und P = {S  $\rightarrow$  Ac | dS |  $\epsilon$ , A  $\rightarrow$  aB | cA | d, B  $\rightarrow$  b |  $\epsilon$  }
- Führen Sie die Beispiele auch mit FLACI aus.

#### Steuermengen

- Eine kontextfreie Grammatik ist genau dann eine LL(1)-Grammatik, wenn für jedes Nichtterminal A mit A  $\rightarrow \alpha_1 \mid \alpha_2 \mid \alpha_3 \mid \dots \mid \alpha_n$  gilt:
  - ▶ Die Mengen FIRST<sub>1</sub>( $\alpha_1$ ), ... ,FIRST<sub>1</sub>( $\alpha_n$ ) sind paarweise disjunkt,
  - Genaue eine Menge  $FIRST_1(\alpha_i)$  darf das leere Wort enthalten. Dafür muss dann die zugehörige  $FOLLOW_1(A)$  disjunkt zu allen anderen  $FIRST_1(\alpha_i)$  sein.
- Dig Steuermengen vereinfachen sich zu:
  - $D(A \rightarrow \alpha_i) := FIRST_1(\alpha_i) \text{ falls } \epsilon \notin FIRST_1(\alpha_i) \text{ oder}$   $(FIRST_1(\alpha_i) \{\epsilon\}) \cup FOLLOW_1(A) \text{ sonst}$

## Aufgaben LL(1)

Gehören folgende Grammatiken zu LL(1)?

- G(N,  $\Sigma$ , P, S) mit N = {A,B, S},  $\Sigma$ ={x,y,z} und P = {S  $\rightarrow$  A | B, A  $\rightarrow$  x A | y, B  $\rightarrow$  x B | z }
- $G(N, \Sigma, P, K)$  mit  $N = \{K,E,S\}$ ,  $\Sigma = \{a,b,d,c\}$  und  $P = \{K \rightarrow S \mid \epsilon, S \rightarrow a S b \mid E,E \rightarrow d \mid c E\}$

Begründen Sie ihre Aussagen. Überprüfen Sie dies mit FLACI.

#### Berechnung von FIRST-Mengen

- Systematisches Verfahren:
  - Bestimmen einer Menge  $N_{\epsilon}$  aller Nichtterminale aus denen das leere Wort abgeleitet werden kann  $N_{\epsilon} := \{ X \in N \mid X \Rightarrow^* \epsilon \}$
  - Man zeichne einen Graphen, dessen Knoten die Nichtterminale sind. Für jede Produktion  $A \rightarrow X_1...X_m$  mit dem Nichtterminal  $X_1$  füge eine gerichtete  $A \rightarrow X_1$  Kante ein.
    - Falls  $X_1 \in N_{\epsilon}$  und  $X_2$  ein Nichtterminal füge eine Kante  $A \to X_2$  hinzu. Falls  $X_1 \in N_{\epsilon}$  und  $X_2 \in N_{\epsilon}$  und  $X_3$  ein Nichtterminal füge eine Kante  $A \to X_3$  hinzu, usw.
- Eine Kante A →B drückt aus: FIRST(B) sollte vor FIRST(A) berechnet werden.


Betrachte folgende Grammatik G<sub>2</sub>


```
stmt
                  assignment | cond | loop
assignment → id := expr
             → if boolexpr then stmt cond-rest
cond
cond-rest → fi | else stmt fi
             → while boolexpr do stmt od
loop
             → boolexpr | numexpr
expr
             \rightarrow
boolexpr
                  numexpr cop numexpr
             → term nexpr | term
numexpr
             \rightarrow + term nexpr | \epsilon
nexpr
term
             → factor nterm | factor
nterm
             → * factor nterm | ε
factor
             → id | const | (numexpr)
```

Die Menge  $N_{\epsilon} := \{\text{nterm, nexpr}\}$ 

Graphen zu den FIRST-Mengen

- Graphen zu der Berechnung der FIRST-Mengen
  - Berechnen der FIRST-Mengen von assigment, cond und loop zuerst und dann die FIRST-Menge von stmt
  - Berechnen der FIRST-Menge von factor, dann die von term, dann die von numexpr, dann die von boolexpr. Am Schluss wird die FIRST-Menge von expr berechnet.
  - Die FIRST-Mengen zu cond-rest, nexpr, nterm sind unabhängig





Die FIRST- und Steuermengen

FIRST-Mengen	Produktion		Steuermengen D
{id}	assignment →	id := expr	{id}
{if}	$cond \rightarrow cond-rest$	if boolexpr then stmt	{if}
{fi, else}	cond-rest →	fi	{fi}
		else stmt fi	{else}
{while}	loop →	while boolexpr do stmt od	{while}
{id, if,while}	stmt →	assigment	{id}
		cond	{if}
		loop	{while}
{id,const,(}	factor →	id	{id}
		const	{const}
		( expr )	{(}
{id,const,(}	term →	factor nterm	{id,const,(}
{id,const,(}	numexpr →	term nexpr	{id,const,(}
{id,const,(}	boolexpr →	numexpr cop numexpr	{id,const,(}
{id,const,(}	expr →	boolexpr	{id,const,(}
		numexpr	{id,const,(}

G<sub>2n</sub> gehört zu LL(1)

- Beobachtung:
  - Die Steuermengen für die Produktion expr sind nicht disjunkt.
  - $\Rightarrow$  die Grammatik G<sub>2</sub> gehört nicht zu LL(1)
- Das Problem liegt an der Produktion von expr

#### expr → boolexpr | numexpr


Ein Token-Vorausschau reicht nicht um zwischen den beiden Produktionen zu entscheiden.


Das lässt sich beheben durch folgende Produktionen:

expr  $\rightarrow$  numexpr bool-rest boolrest  $\rightarrow$  cop numexpr |  $\epsilon$ 

Betrachte folgende Grammatik G<sub>2n</sub> stmt → assignment | cond | loop assignment  $\rightarrow$  id := expr cond → if boolexpr then stmt cond-rest cond-rest  $\rightarrow$  fi | else stmt fi loop→ while boolexpr do stmt od expr → numexpr bool-rest boolrest → cop numexpr | ε boolexpr → numexpr cop numexpr numexpr → term nexpr nexpr  $\rightarrow$  + term nexpr |  $\epsilon$ term → factor nterm nterm → \* factor nterm | ε factor  $\rightarrow$  id | const | (expr)

- Die Menge  $N_ε$  := {nterm, nexpr, boolrest}
  - Für diese Produktionen müssen die FOLLOW-Mengen bestimmt werden.
- Die Graphen zur Berechnung der FIRST-Mengen





Die FIRST- und Steuermengen

FIRST-Mengen	Produktion		Steuermengen D
{id, if,while}	$stmt \rightarrow$	assigment	{id}
		cond	{if}
		loop	{while}
{id}	assignment $\rightarrow$	id := expr	{id}
{if}	cond → rest	if boolexpr then stmt cond-	{if}
{fi, else}	cond-rest $\rightarrow$	fi	{fi}
		else stmt fi	{else}
{while}	loop →	while boolexpr do stmt od	{while}
{id,const,(}	expr →	boolexpr bool-rest	{id,const,(}
{cop}	bool-rest→	cop numexpr	{cop}
		ε	{\$, od, fi, else,)}
{id,const,(}	boolexpr →	numexpr cop numexpr	{id,const,(}

Die FIRST- und Steuermengen

FIRST- Mengen	Produktion		Steuermengen D
{id,const,(}	$numexpr \rightarrow$	term nexpr	{id,const,(}
{+}	nexpr→	+ term nexpr   ε	{+} {\$, od, fi, else,), then, do,cop}
{id,const,(}	term →	factor nterm	{id,const,(}
<b>{*}</b>	nterm →	* factor nterm   ε	{*} {\$, od, fi, else,), then, do,cop,+}
{id,const,(}	factor →	id   const   (expr)	{id} {const} {(}

## Aufgabe

Erstellen Sie die beiden vorherigen Grammatiken mit FLACI und überprüfen Sie die First-Mengen.

## Berechnung der FOLLOW-Menge

- Systematisches Verfahren
  - Trage alle Nichtterminale als Knoten in einen Graphen. Der Graph hat noch keine Kanten. Markiere den Knoten mit dem Startsymbol mit dem Symbol \$ (Ende der Eingabe)
  - 2. Betrachte der Reihe nach, alle Produktionen in P. Für jede Produktion jedes Nichtterminal B auf der rechten Seite.
    - A → αBβ mit β ≠ε: Markiere den Knoten B mit allen Symbolen, die in FIRST(β) liegen. Falls ε ∈ FIRST(β), dann füge eine Kante A → B hinzu.
    - 2.  $A \rightarrow \alpha B$ : Füge die Kante  $A \rightarrow B$  hinzu.
  - 3. Falls es Zyklen gibt, werden alle Knoten des Zyklus gleich behandelt
  - 4. Die FOLLOW-Menge eines Nichtterminals ist die Vereinigung seiner eigenen Markierungen mit den Markierungen aller seiner Vorgänger im Graphen.

Die Follow-Mengen als Graphen

Aufbau des Graphen laut Vorschrift der vorherigen Folie

Nach dem 1. Schritt (alle Nichterminale + \$ an Startknoten)

```
stmt
stmt \rightarrow
           assignment | cond | loop
assignment →
                 id := expr
cond →
           if boolexpr then stmt cond-rest
                                              assignmen
                                                                          cond
                                                                                                gool
cond-rest
                 fi | else stmt fi
           while boolexpr do stmt od
loop ->
                                                                       cond-rest
           numexpr bool-rest
expr/
boolrest
                 cop numexpr | ε
boolexpr
                 numexpr cop numexpr
                                                                       bool-rest
                                                   expr
numexpr
                 term nexpr
           \rightarrow
                 + term nexpr | ε
nexpr
                                                                       numexpr
                                                                                               nexpr
term →
           factor nterm
nterm
                 * factor nterm | E
                                                boolexpr
factor
                 id | const | (expr)
           \rightarrow
                                                                          term
                                                                                               nterm
```

factor

Die Follow-Mengen als Graphen

Aufbau des Graphen laut Vorschrift der vorherigen Folie


Während des 2. Schrittes (A  $\rightarrow \alpha$ B: Füge die Kante A  $\rightarrow$  B hinzu und bei A  $\rightarrow \alpha$ B, falls  $\epsilon \in FIRST(\beta)$ , dann füge eine Kante A  $\rightarrow$  B hinzu \$ stmt  $stmt \rightarrow$ assignment | cond | loop assignment → id := expr loop <u>assignment</u> cond if boolexpr then stmt cond-rest cond → cond-rest / fi | else stmt fi while boolexpr do stmt od loop -> cond-rest numexpr bool-rest expr/ boolrest cop numexpr | ε bool-rest expr boolexpr numexpr cop numexpr  $\rightarrow$ numexpr term nexpr  $\rightarrow$ + term nexpr | ε nexpr  $\rightarrow$ numexpr nexpr factor nterm term → nterm \* factor nterm | E boolexpr nterm factor id | const | (expr) term  $\rightarrow$ factor

Die Follow-Mengen als Graphen

Aufbau des Graphen laut Vorschrift der vorherigen Folie


Nach dem 2. Schritt (A  $\rightarrow \alpha$ B $\beta$  mit  $\beta \neq \epsilon$ : Markiere den Knoten B mit allen Symbolen, die in FIRST( $\beta$ ) liegen).

```
stmt \rightarrow
              assignment | cond | loop
assignment →
                    id := expr
cond →
             if boolexpr then stmt cond-rest
                    fi | else stmt fi
cond-rest
             while boolexpr do stmt od
loop →
             numexpr bool-rest
expr/
boolrest
                    cop numexpr | ε
boolexpr
                    numexpr cop numexpr
              \rightarrow
                    term nexpr
numexpr
              \rightarrow
                    + term nexpr | ε
nexpr
              \rightarrow
                    factor nterm
term
              \rightarrow
nterm
                    * factor nterm | E
factor
                    id | const | (expr)
             \rightarrow
```




Die Follow-Mengen als Graphen

- Aufbau des Graphen laut Vorschrift der vorherigen Folie
  - Nach dem 4. Schritt



#### Aufbau eines prädikativen Analysators Analysetabelle - Prinzip

- Für eine LL(1) Grammatik lassen sich prädikative Parser recht einfach erstellen.
  - Die richtigen Produktionen lassen sich anhand des gelesene Eingabezeichen eindeutig bestimmen.
  - Man kann damit ein PDA erstellen.



Analysetabelle-Beispiel

Betrachte folgende reduzierte Grammatik G<sub>a</sub> (Teilgrammatik G<sub>2n</sub>)

Grammatik-Regeln			Nummer	Steuermenge
numexpr	$\rightarrow$	term nexpr	(1)	{id,const,(}
nexpr	$\rightarrow$	+ term nexpr	(2)	{+}
		3	(3)	{\$,)}
term	$\rightarrow$	factor nterm	(4)	{id,const,(}
nterm	$\rightarrow$	* factor nterm	(5)	{*}
		3	(6)	{\$,),+}
factor	$\rightarrow$	id	(7)	{id}
		const	(8)	{const}
		(expr)	(9)	{(}

- Damit lassen sich Ausdrücke formulieren wie
  - id\*(id+id\*(id+id))
  - id+id\*const

#### Aufbau eines prädikativen Analysators Analysetabelle- Tabelle

- Analysetabelle: für jedes Nichtterminal und jedes Eingabezeichen
  - Spalte zeigt die Nummer der Produktion an, die gewählt wird
  - Wo keine Einträge sind, liegt ein Fehlerzustand vor.

	Eingabesymbol						
Nichtterminal	id	const	+	*	(	)	\$
numexpr(E)	1	1			1		
nexpr(N)			2			3	3
Term (T)	4	4			4		
nterm(R)			6	5		6	6
factor(F)	7	8			9		

Analysetabelle-Funktionsweise des Kellerautomaten

Betrachte den Eingabestring: id+id\*id

Stack	Eingabe	Regel
E\$	id+id*id\$	
TN\$	id+id*id\$	1
FRN\$	id+id*id\$	4
idRN\$	id+id*id\$	7
RN\$	+id*id\$	Match(id)
N\$	+id*id\$	6
+TN\$	+id*id\$	4
+TN\$	+id*id\$	Match(+)
FRN\$	id*id\$	4
idRN\$	id*id\$	7
RN\$	*id\$	Match(id)

Stack	Eingabe	Regel	
RN\$	*id\$	Match(id)	
*FRN\$	*id\$	5	
FRN\$	id\$	Match(*)	
idRN\$	id\$	7	
RN\$	\$	Match(id)	
N\$	\$	6	
\$	\$	6	
		Match(\$)	

rekursiver Abstieg - Prinzip

- Rekursives Parsing besteht aus einer Gruppe von Prozeduren.
  - Eine Prozedur für jedes Nichtterminal
  - Eine Startprozedur, welche die anderen Prozeduren aufruft und anhält wenn der Eingabestring erfolgreich gelesen wurde.
- Pseudocode:

```
void procedure A() { // Prozedur zum Nichtterminal A

// Wähle eine A-Produktion A→X₁..Xn;

for(i = 1 bis n) {
    if(X ein Nichtterminal) call X(); // rufe Prozedur zu X;
    else if (X = dem aktuelle Eingabezeichen) call nexttoken();
    else // Fehleroutine aufrufen!
}
```

rekursiver Abstieg - Beispiel

■ Betrachte den Ausschnitt
stmt → assignment | {id}
cond | {if}
loop {while}
assignment →id := expr {id}

Aufbau der Prozeduren

```
procedure stmt() {
    if (token == 'id') assigment();
    elseif(token == 'if') cond();
    elseif(token== 'while') loop;
    else error();
}
```

```
procedure assigment() {
   if(token == 'id') {
    match('id');
    match(':=');
    expr();
   else error();
procedure match(token t){
   if(token == t) nexttoken();
   else error:
```